

1

안녕하세요, 컴퓨터 비전 팀 3조 Brain Tumor 데이터 증강 및 다양한 ResNet 아키텍처 활용한 성능 비교 발표를 맡은 이승우입니다.

---

2

발표 시작에 앞서, 목차는 다음과 같습니다. 먼저 주제선정 이유, ResNet에 대한 간략한 설명, 데이터 선택 및 한계, ResNet 구현, 결과 비교, 마지막으로 결론 및 보완점을 발표하겠습니다.

---

3

우측 그래프는 세계 디지털 헬스케어 시장의 규모를 보이는데, 보시는 것처럼 연평균 성장률이 25%에 이르는 가파른 성장세를 보이며 인공지능을 통한 신약 연구, 질병 탐지 등을 파악하고 있습니다. 이에 이미지 처리를 통한 뇌종양 진단하는 모델을 구축하여 초기진단이 매우 중요한 질병인 뇌종양을 진단하는 프로젝트를 진행했습니다. 해당 데이터는 케글에서 구하여 진행했습니다..

---

4

모델훈련은 ResNet을 통하여 진행했습니다. ResNet 관련 내용은 최근 세션에서 진행했기때문에 자세한 설명은 생략하도록 하겠습니다. ResNet의 핵심 아이디어는 과거 모델에서 숏컷 커넥션을 통해 layer가 깊어질수록 좋아지는 결과를 보인 모델입니다. 저희는 ResNet 18 레이어와 50 레이어를 비교하였습니다.

---

5

로드맵은 다음과 같습니다.

먼저 데이터 전처리 및 증강, ResNet 18 레이어와 50 레이어 구현, 훈련이 모두 마친 후, 원본데이터와 증강데이터 결과를 비교합니다.

---

6

먼저 원본 데이터는 총 253개의 이미지로 구성되어 있습니다. 모든 데이터는 레이블링이 되어있으며 뇌종양 환자의 데이터가 예스로, 뇌종양이 아닌 환자의 데이터가 노로 할당되어있습니다.

---

7

해당 데이터에 먼저 이미지 컨투어 작업을 진행했습니다.

이미지 컨투어 기술은 이미지 내에서 객체를 식별하고, 형태를 분석하여 객체의 위치와 크기를 파악하는데 사용됩니다. 이미지 컨투어를 사용하는 주된 이유는 이미지 처리 및 컴퓨터 비전 분야에서 객체인식과 분류를 효율적으로 수행하기 위함입니다.

이미지 컨투어를 통하여 이미지 안의 뇌의 가장 외곽선을 찾고, 외곽선을 따라 이미지를 크롭하여 훈련이 용이하도록 만들었습니다.

---

8

이후, 진행한 것은 이미지 증강입니다.

이미지 증강은 기존의 이미지 데이터셋을 수정하거나 변형하여 새로운 이미지를 만드는 기술입니다. 이는 특히 소규모 데이터셋으로도 효과적인 학습이 가능하게 하며, 모델이 실제 세계의 복잡성과 변동성을 더 잘 이해하고 처리할 수 있도록 합니다.

앞서 보신것과 같이 데이터의 총 253개로 모델을 훈련시키기에 상당히 낮은 수의 데이터를 가지고 있습니다. 따라서 이미지 증강을 통해 훈련 데이터를 키우고자 했습니다. 총 증강된 데이터는 훈련데이터 하나당 20개의 데이터로 진행했습니다.

---

9

한 이미지 데이터에 대하여 이미지 회전, 가로 이동, 세로 이동, 밝기 변환 등을 랜덤으로 조합하여 증강을 진행했습니다. 이에 따라 훈련 데이터는 4228개로 많이 증가하였고, 이 데이터를 통해 훈련을 진행했습니다. 원본 데이터로 훈련을 진행한 결과와, 증강한 데이터로 훈련을 진행한 결과를 비교하여 성능이 개선이 됐는지 확인하는 작업도 진행하였습니다.

---

10

다음으로 ResNet 구현에 대해 설명하겠습니다.

동일한 출력 feature map 크기에 대해 동일한 수의 필터가 있는 레이어와 레이어당 시간 복잡성을 유지하기 위해 feature map 크기가 절반으로 줄어드는 경우 필터 수를 두배로 늘렸습니다.

ResNet18의 구조를 살펴보면, 처음에 7x7을 적용한 것을 제외하고는 3x3 사이즈의 커널을 사용했습니다. 중간중간에 보면 사이즈를 반으로 줄일 때가 있는데 그때는 stride를 2로 주고 채널의 깊이를 2배로 늘리면서 layer를 쌓았고, fc layer를 포함해 총 18개의 layer를 쌓았습니다.

---

11

ResNet50의 구조를 살펴보면 7x7 및 3x3 사이즈의 커널을 사용하는 것은 동일하지만, 1x1 convolution을 적용한 것이 차이점입니다. 이것을 적용한 이유는 아무래도 층이 깊어질수록 파라미터 수가 많이질 것이고, 연산 속도 또한 오래 걸리기 때문에 파라미터 개수를 효과적으로 줄이려고 사용하였습니다. 바로 이어지는 stage로 연결될 때마다 ResNet18과 동일하게 Feature map의 크기는 절반으로 줄고 채널의 깊이를 2배로 늘리면서 layer를 쌓았고, fc layer를 포함해 총 50개의 layer를 쌓았습니다.

---

12

다음으로 앞에서 간단하게 설명드린 Brain Tumor 데이터를 분류하기 위해 ResNet 18과 ResNet 50을 구현하고 평가한 프로젝트 결과를 말씀드리겠습니다.

저희 조 목표는 논문에서와 같이 ResNet의 깊이가 증가함에 따라 성능이 향상되는지, 그리고 데이터 증강 기법을 적용하여 모델의 성능을 향상시킬 수 있는지 확인하는 것이었습니다.

먼저, 저희는 원본 데이터에 대해 ResNet 18과 ResNet 50을 학습하고 테스트했습니다.

---

13

그 결과, 두 모델 모두 원본 데이터에 대해 0.72의 정확도를 보였습니다. 그러나 원본 이미지 개수는 총 253개였기 때문에 학습 데이터가 부족하여 모델의 성능을 신뢰하기 어렵다고 판단했습니다.

---

14

원본데이터 Resnet 18 성능을 시각화 한 그래프입니다

---

15

원본데이터 Resnet 50 성능을 시각화 한 그래프입니다

---

16

이후, 저희는 Brain Tumor 데이터에 대해 다양한 데이터 증강 기법을 적용하여 데이터를 증가시킨 후 ResNet을 학습하고 테스트했습니다.

---

17

결과적으로, ResNet 18의 경우 데이터 증강 후 정확도가 0.5로 감소했지만, ResNet 50의 경우 정확도가 0.75로 향상되었습니다. 이는 ResNet 50이 더 깊은 네트워크 구조를 가지고 있어 더 많은 데이터나 데이터 증강에 더 잘 대응할 수 있다는 것을 확인할 수 있었습니다.

---

18

마찬가지로 증강데이터 Resnet 18 성능을 시각화 한 그래프입니다

---

19

증강데이터 Resnet 50 성능을 시각화 한 그래프입니다

---

20

이번 프로젝트를 통해 데이터 증강이 모델 성능에 미치는 영향과 ResNet의 깊이가 분류 성능에 미치는 영향을 분석했습니다. 우리는 논문에서 발견된 결과와 유사하게 ResNet 50이 ResNet 18보다 더 뛰어난 성능을 보였으며, 더 깊은 네트워크 구조를 가지고 있어 데이터 증강에 더 잘 적응하는 것으로 판단할 수 있었습니다. 그러나 데이터 양이 여전히 부족하여 모델의 정확도가 높지 않았습니다. 따라서 향후 프로젝트에서는 데이터 양을 늘리는 방법을 탐구할 필요가 있다고 판단했습니다.

---

21

또한, 다양한 데이터 증강 기법 외에도 모델 구조를 조합하여 성능을 더 향상시킬 수 있는 연구가 필요합니다. 예를 들어 GAN을 활용한 데이터 생성 및 증강, Attention 기반 모델 등을 적용하는 것이 가능할 것입니다. 이러한 추가적인 활동을 통해 더 나은 모델을 개발하는 데 기여할 수 있을 것으로 기대됩니다.

이상으로 cv 프로젝트를 발표를 마치겠습니다. 감사합니다.